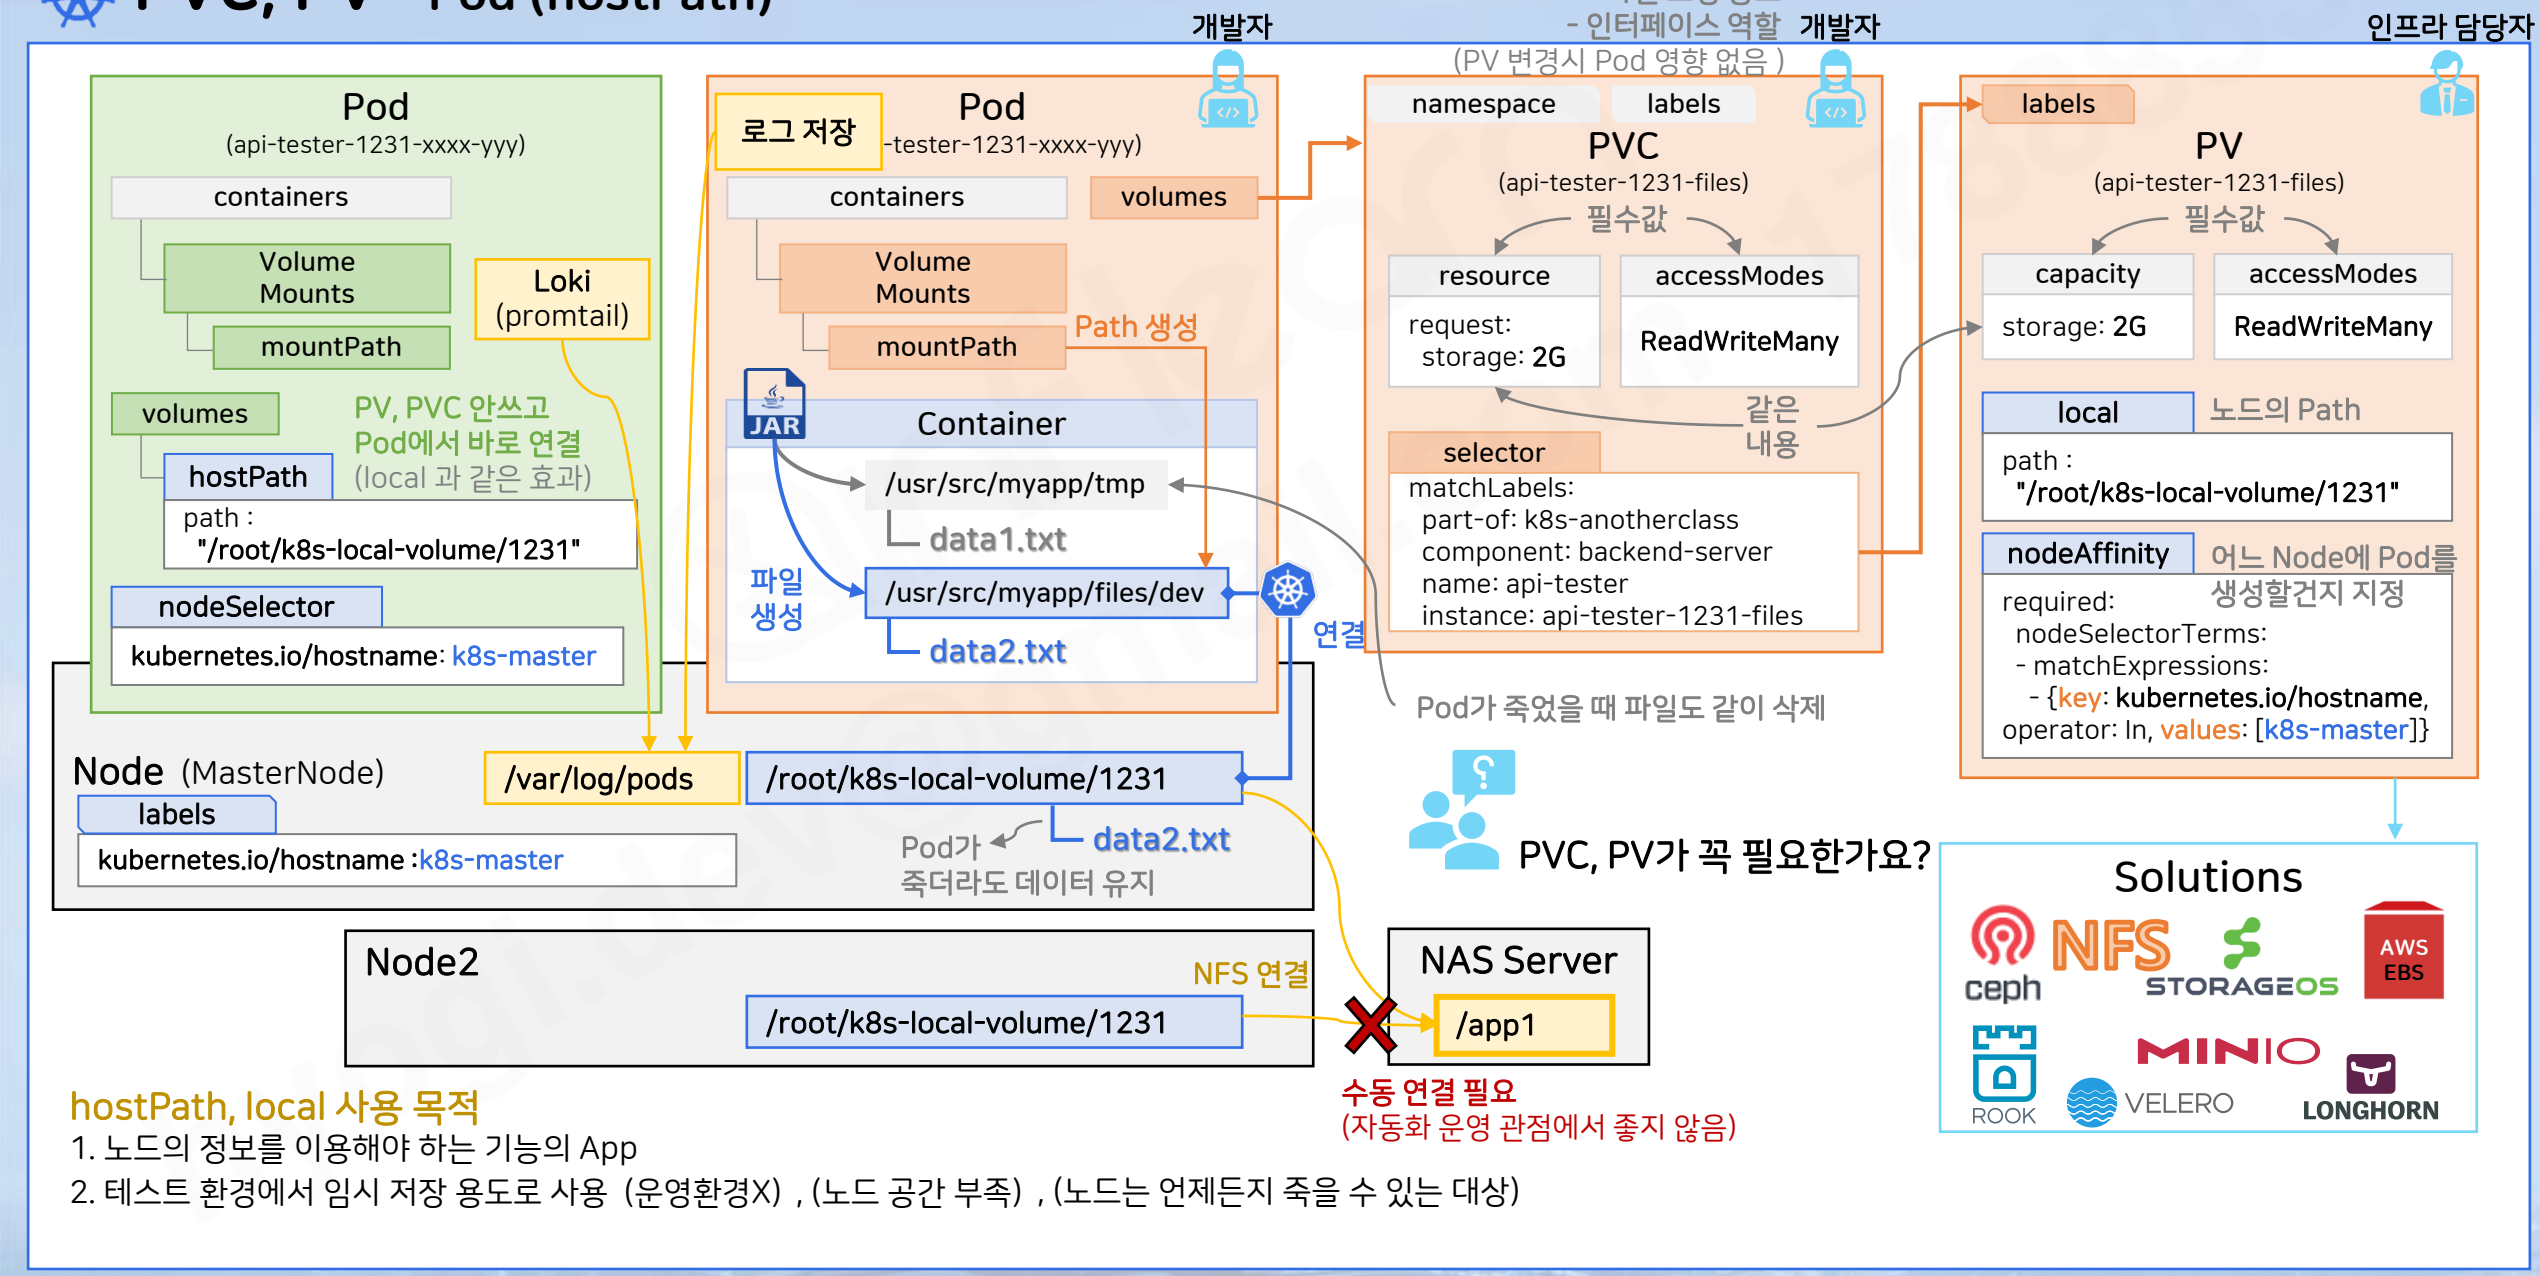

KubeOps
상위 1% 월급쟁이를 위한
쿠버네티스 어나더 클래스
Application 기능을 이해하기
PVC, PV / Deployment / HPA / Service

PVC, PV - Pod (hostPath)

Application 기능으로 이해하기



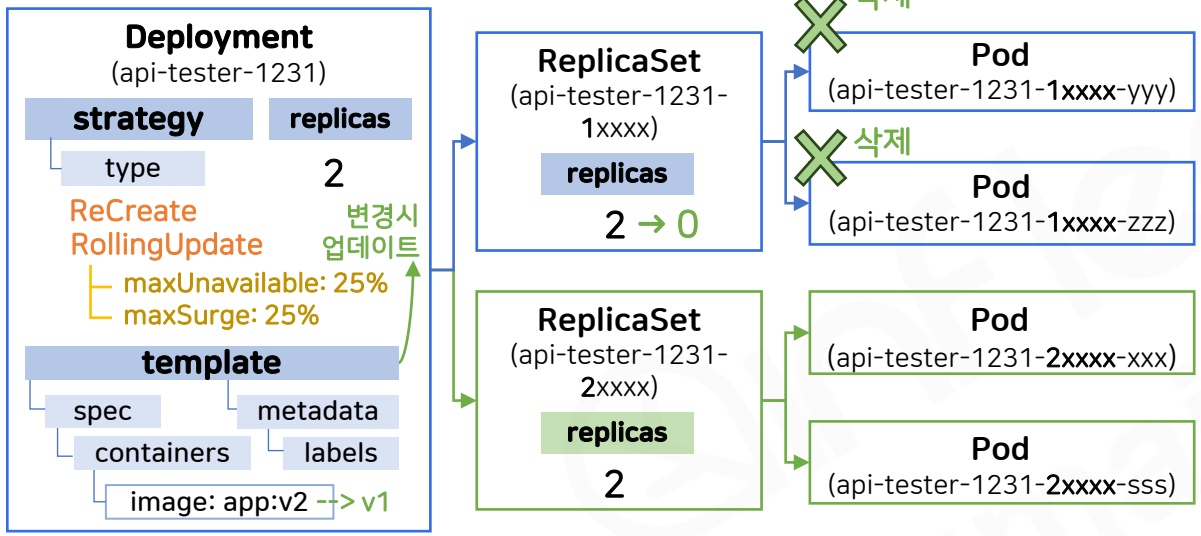
hostPath, local 사용 목적

1. 노드의 정보를 이용해야 하는 기능의 App
2. 테스트 환경에서 임시 저장 용도로 사용 (운영환경X) , (노드 공간 부족) , (노드는 언제든지 죽을 수 있는 대상)

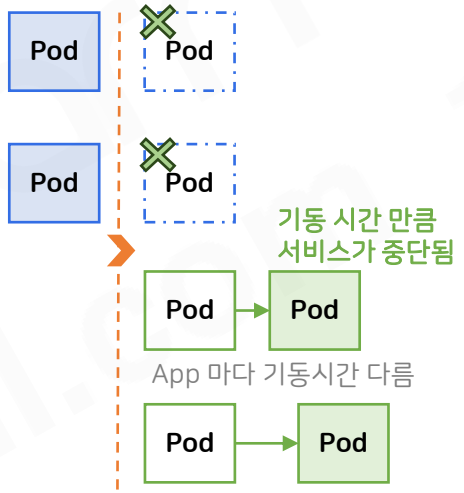
Deployment - update

Application 기능으로 이해하기

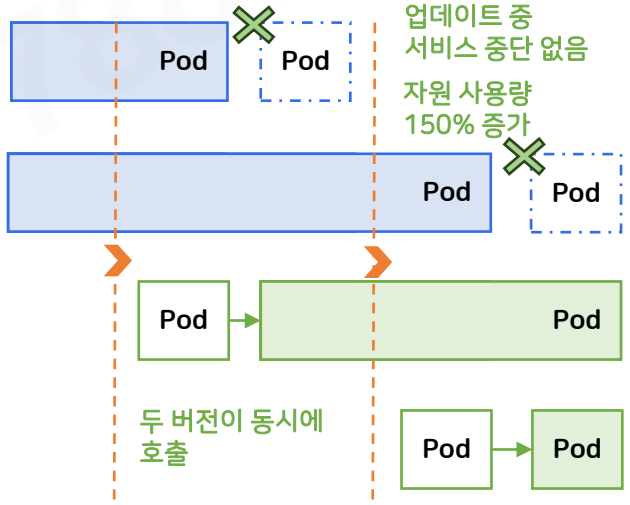
Deployment Udpate



Recreate



RollingUpdate

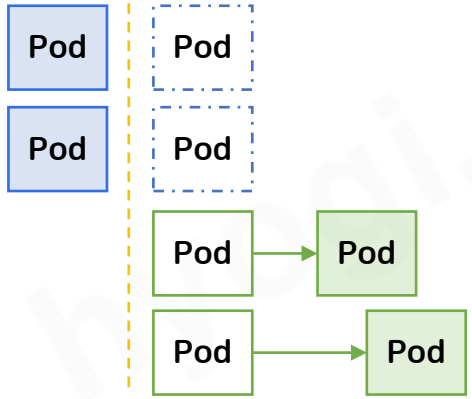


[Blue/Green]
- 업데이트 동안 두 버전이 동시에 호출되지 않음
- 자원 사용량 200% 증가
- 별도 배포 솔루션에서 제공

RollingUpdate - maxUnavailable, maxSurge

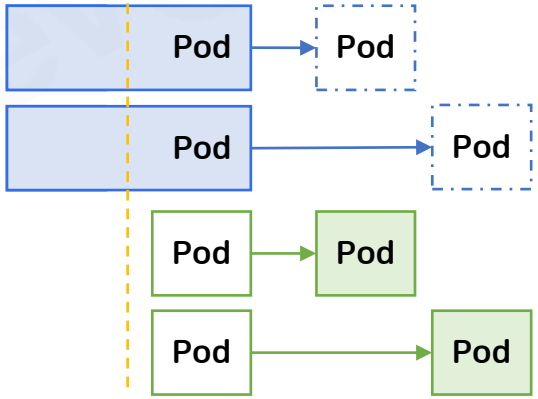
maxUnavailable: 100%
maxSurge: 100%

Recreate와 같은 효과

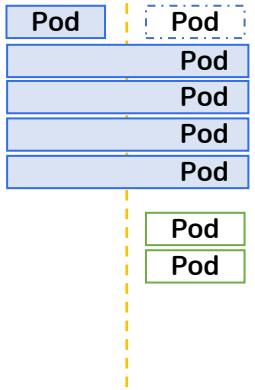


maxUnavailable: 0%
maxSurge: 100%

Blue/Green에 가까운 효과

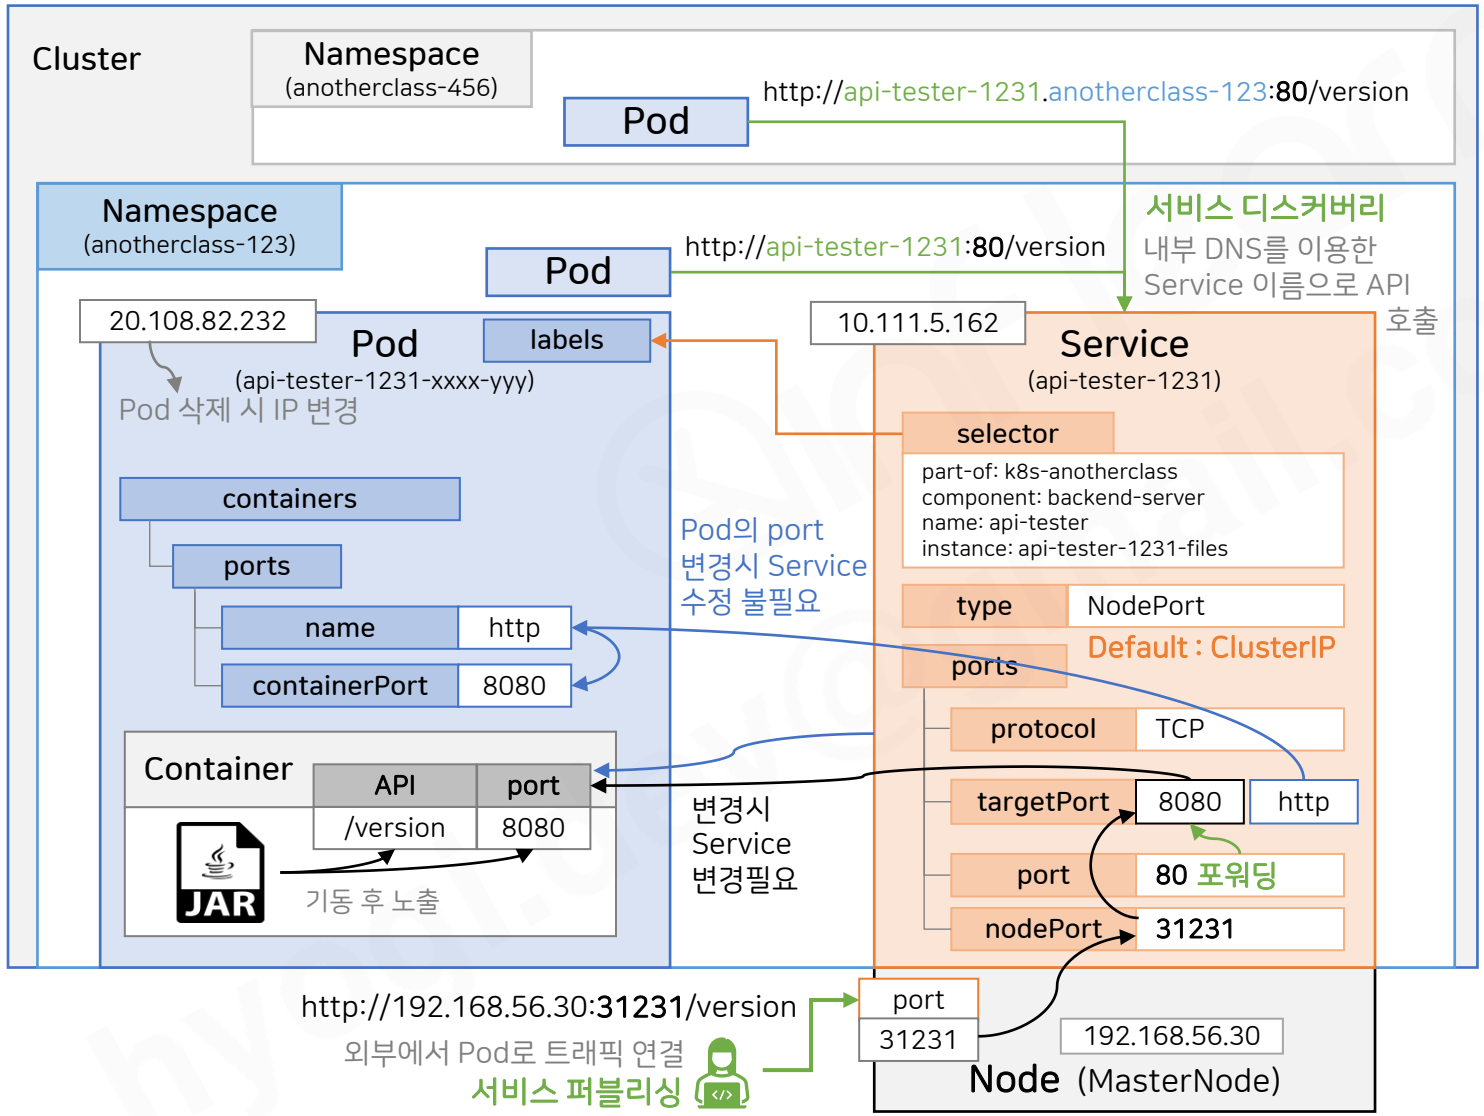


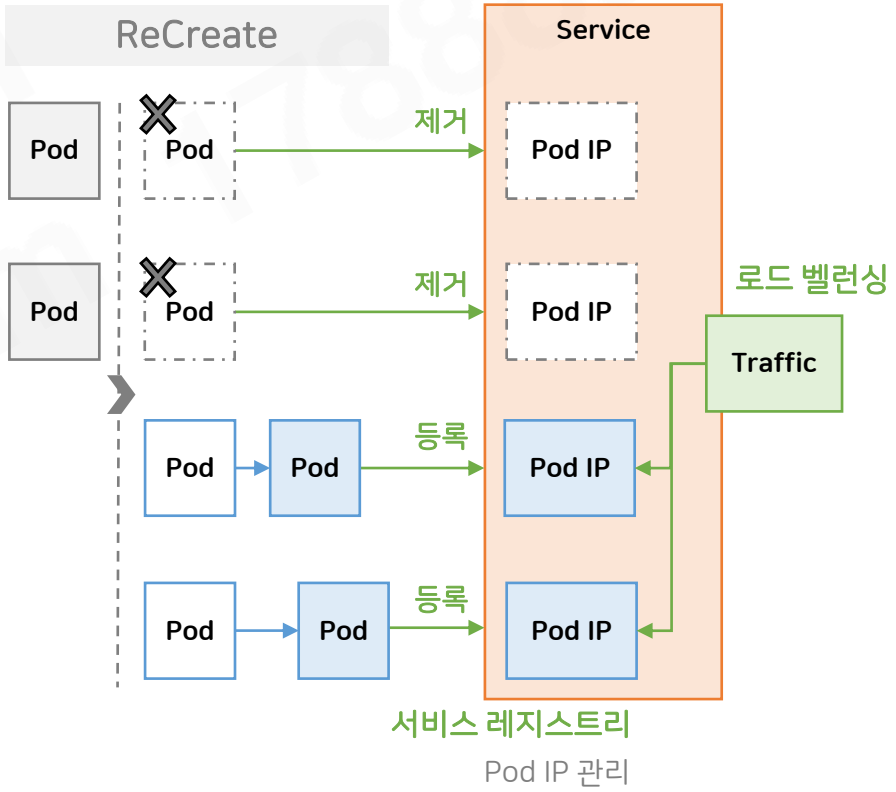
maxUnavailable: 25%
maxSurge: 25%



Service

Application 기능으로 이해하기



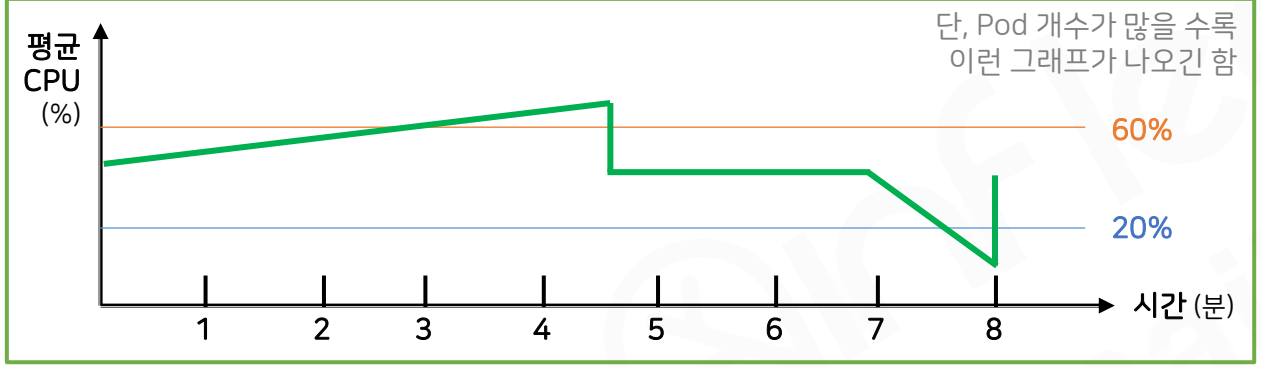


HPA

Application 기능으로 이해하기

[이상적인 스케일링]

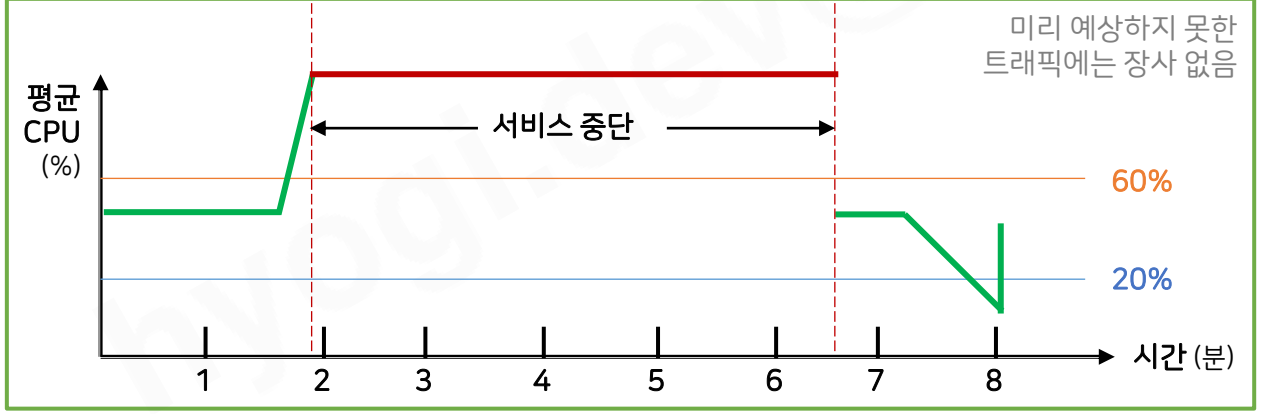




단, Pod 개수가 많을 수록 이런 그래프가 나오긴 함

[현실적인 스케일링]





미리 예상하지 못한 트래픽에는 장사 없음

HPA
(api-tester-1231-default)

scaleTargetRef
apiVersion: apps/v1 kind: **Deployment** name: api-tester-1231

minReplicas	2
maxReplicas	4

metrics

```
- type: Resource
  resource:
    name: cpu
    target:
      type: Utilization
      averageUtilization: 60
```

수치를 결정하는데 영향도가 큼

현재 Pod 수 * (평균 CPU / HPA CPU)
→ 변경될 Pod 수

2 * (((150+1)/2) / 60) = 3 (2.51)

behavior 잦은 스케일링 방지

```
scaleUp:
  stabilizationWindowSeconds: 120
scaleDown
  stabilizationWindowSeconds: 600
  policies:
    - type: Pods
      value: 1
      periodSeconds: 60
```

1분에 1개씩 Pod 제거

2분 동안 60%이상 유지시 scaleOut

부하가 감소해도 10분동안은 Pod 수 개수

Deployment
(api-tester-1231)

replicas	2

ReplicaSet

Pod -Xmx 50M

resource	container
limits: cpu: 200m memory: 200Mi	200%
requests: cpu: 100m memory: 100Mi	150m (CPU) 70m (CPU) 40Mi (Memory)

100% 계산을 위한 기준 값

CPU Memory

부하에 따른 증감 대상 아님